Monitoreo Automatizado de Fauna Silvestre mediante YOLOv8s Utilizando el Dataset Caltech Camera Traps (CCT20)

Danny Branco Ramos Condori
Universidad Nacional de Ingeniería
Lima, Perú
danny.ramos.c@uni.pe

Percy Marcovich Osorio Medina
Universidad Nacional de Ingeniería
Lima, Perú
percy.osorio.m@uni.pe

Daniel Eduardo Palomino Pacahuala
Universidad Nacional de Ingeniería
Lima, Perú
daniel.palomino.p@uni.pe

Henry Marcos Valdivia Zevallos
Universidad Nacional de Ingeniería
Lima, Perú
henry.valdivia.z@uni.pe

César Elías Verde Mendocilla
Universidad Nacional de Ingeniería
Lima, Perú
cesar.verde.m@uni.pe

Resumen

Las cámaras trampa constituyen una de las herramientas más utilizadas para el monitoreo de biodiversidad debido a su capacidad para registrar fauna silvestre de forma continua y no invasiva. Sin embargo, la gran cantidad de imágenes generadas dificulta su análisis manual. En este trabajo se desarrolló un sistema de detección automática de fauna basado en YOLOv8s utilizando el dataset Caltech Camera Traps (CCT20). El modelo fue entrenado con 13.553 imágenes y evaluado tanto sobre la partición CIS (ubicaciones similares a las observadas durante el entrenamiento) como sobre la partición TRANS (ubicaciones completamente nuevas). Los resultados obtenidos muestran un desempeño de mAP@0.5 igual a 0.847 y mAP@0.5:0.95 igual a 0.614 sobre la partición CIS. Al evaluar sobre ubicaciones no observadas durante el entrenamiento, el desempeño disminuyó hasta 0.506 y 0.366 respectivamente, evidenciando una importante brecha de generalización geográfica. Adicionalmente, se implementó un módulo de monitoreo ecológico capaz de transformar detecciones individuales en reportes automáticos de actividad por especie.

Palabras clave: YOLOv8, cámaras trampa, monitoreo de fauna, detección de objetos, aprendizaje profundo, biodiversidad.

1 Introducción

El monitoreo de fauna silvestre constituye una actividad fundamental para la conservación de ecosistemas y la gestión de áreas naturales protegidas. Durante las últimas décadas, las cámaras trampa han permitido recopilar grandes volúmenes de información sobre presencia, abundancia y comportamiento de especies animales.

No obstante, la revisión manual de estas imágenes representa una tarea costosa en tiempo y recursos humanos. Como consecuencia, el uso de técnicas de visión por computador y aprendizaje profundo se ha convertido en una alternativa atractiva para automatizar el procesamiento de datos ecológicos.

Entre las arquitecturas de detección de objetos más utilizadas destaca YOLO (*You Only Look Once*), debido a su capacidad para combinar precisión y velocidad de inferencia [6, 1]. En este contexto, el presente trabajo propone la implementación de un detector de fauna basado en YOLOv8s utilizando el benchmark Caltech Camera Traps (CCT20), uno de los conjuntos de datos de referencia para monitoreo automatizado de fauna mediante cámaras trampa [2]. Se evalúan tanto su capacidad de detección como su capacidad de generalización a nuevas ubicaciones geográficas. El código del proyecto está disponible en `https://github.com/percysorio/Pregunta3-cct20-yolov8-wildlife-monitoring`.

2 Motivación del estudio

El monitoreo de fauna silvestre es una actividad esencial para la conservación de la biodiversidad y la toma de decisiones en gestión ambiental. Las cámaras trampa permiten registrar animales de forma continua y no invasiva, generando grandes volúmenes de información visual. Sin embargo, la revisión manual de miles de imágenes representa una tarea costosa, repetitiva y susceptible a errores humanos.

Los avances recientes en aprendizaje profundo han demostrado que los detectores de objetos pueden automatizar gran parte de este proceso. No obstante, un desafío importante consiste en determinar si estos sistemas mantienen un desempeño adecuado cuando son desplegados en ubicaciones geográficas distintas de aquellas utilizadas durante el entrenamiento. Esta capacidad de generalización resulta crítica para aplicaciones reales de conservación.

Por ello, este trabajo busca evaluar la efectividad de YOLOv8s para la detección automática de fauna utilizando el dataset CCT20, así como analizar su comportamiento frente a escenarios de transferencia geográfica mediante la comparación entre las particiones CIS y TRANS. Los resultados obtenidos permiten comprender las fortalezas y limitaciones actuales de los sistemas de visión por computador aplicados al monitoreo ecológico.

3 Trabajos relacionados

Durante los últimos años se han desarrollado diversos sistemas basados en aprendizaje profundo para automatizar el análisis de imágenes obtenidas mediante cámaras trampa. Los modelos de la familia YOLO [6, 7, 1] han sido ampliamente utilizados debido a su capacidad para realizar detección en tiempo real manteniendo un equilibrio adecuado entre precisión y velocidad.

El benchmark CCT20 fue introducido por Beery et al. [2] como un entorno de evaluación para estudiar problemas de generalización en sistemas de monitoreo de fauna. Los autores demostraron que los modelos suelen experimentar reducciones significativas de desempeño cuando son aplicados a cámaras no observadas durante el entrenamiento, fenómeno conocido como transferencia de dominio geográfico.

Posteriormente, diversos trabajos han confirmado que las diferencias en iluminación, vegetación, orientación de cámaras y comportamiento de las especies generan sesgos que afectan la capacidad de generalización de los modelos [3, 5]. Asimismo, investigaciones recientes destacan que la presencia de clases desbalanceadas y objetos de pequeño tamaño continúa siendo uno de los principales desafíos en aplicaciones ecológicas basadas en visión por computador.

En este contexto, el presente estudio extiende dichos trabajos mediante la implementación de YOLOv8s y el análisis comparativo de su desempeño sobre escenarios CIS y TRANS, incorporando además un módulo de monitoreo ecológico para la generación automática de indicadores de biodiversidad.

4 Descripción del conjunto de datos

Los experimentos fueron realizados utilizando el dataset Caltech Camera Traps (CCT20), ampliamente utilizado para la evaluación de algoritmos de detección y clasificación de fauna silvestre

Tabla 1: Características generales del dataset.

Característica	Valor
Imágenes totales	243.100
Ubicaciones de cámara	140
Categorías	21 especies + vacío
Bounding boxes	∼66.000
Imágenes vacías	∼70 %

Tabla 2: Particiones utilizadas.

Partición	Imágenes
Entrenamiento	13.553
Validación CIS	3.484
Validación TRANS	1.725

```
dataset_yolo/
  images/train
  images/val
  labels/train
  labels/val
  cct20.yaml
```

Figura 1: Estructura del dataset en formato YOLO.

Tabla 3: Información generada durante la preparación de datos.

Elemento	Cantidad
Imágenes train	13.553
Imágenes validación	3.484
Labels train	13.553
Labels validación	3.484
Clases	16

[2]. Para este trabajo se utilizó un subconjunto del dataset. La partición TRANS contiene cámaras no observadas durante el entrenamiento y se utiliza para evaluar la capacidad de generalización geográfica del modelo.

5 Metodología

5.1 Preparación de datos

Las anotaciones originales fueron proporcionadas en formato COCO JSON y posteriormente convertidas al formato YOLO. Las coordenadas COCO fueron convertidas desde la representación basada en la esquina superior izquierda del *bounding box* hacia la representación de centro normalizado utilizada por YOLO, expresando las coordenadas relativas respecto al ancho y alto de cada imagen. La estructura final del dataset quedó organizada como se muestra en la Figura 1, y durante el proceso se generaron los elementos de la Tabla 3.

5.2 Configuración del entrenamiento

El entrenamiento se realizó utilizando una GPU NVIDIA RTX 5050 Laptop GPU con 8 GB de memoria dedicada. Se utilizó la arquitectura YOLOv8s implementada mediante la plataforma Ultralytics [1], que incorpora optimizaciones para tareas modernas de detección de objetos. Esta arquitectura fue seleccionada por ofrecer un equilibrio adecuado entre consumo computacional y precisión (Tabla 4).

6 Resultados del entrenamiento

6.1 Evolución de las pérdidas

Las funciones de pérdida disminuyeron sostenidamente a lo largo de las 30 épocas (Tabla 5). La reducción observada indica una convergencia estable del modelo.

Tabla 4: Configuración del modelo.

Parámetro	Valor
Arquitectura	YOLOv8s
Resolución	640×640
Batch size	8
Epochs	30
Framework	PyTorch 2.11
Dispositivo	CUDA

Tabla 5: Evolución de las pérdidas de entrenamiento.

Métrica	Época 1	Época 30
Box Loss	1.361	0.994
Classification Loss	2.183	0.418
DFL Loss	1.417	1.125

Tabla 6: Mejor desempeño observado durante el entrenamiento.

Métrica	Valor
Precision	0.851
Recall	0.823
mAP@0.5	0.863
mAP@0.5:0.95	0.614

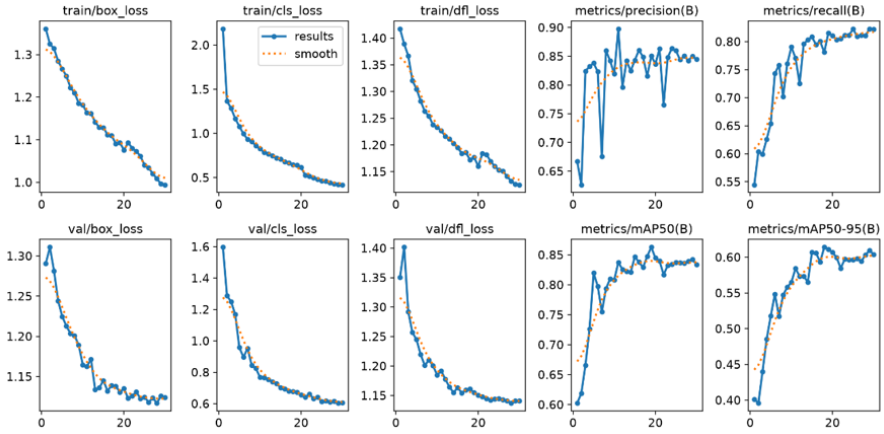


Figura 2: Evolución de las funciones de pérdida y métricas de evaluación durante las 30 épocas de entrenamiento.

6.2 Evolución del desempeño

El mejor rendimiento se observó entre las épocas 18 y 20 (Tabla 6). No se identificaron señales importantes de sobreajuste durante el entrenamiento. La Figura 2 muestra una disminución progresiva de las pérdidas de entrenamiento y validación, acompañada por un incremento sostenido de las métricas de precisión, recall y mAP; la convergencia se estabiliza aproximadamente entre las épocas 18 y 20.

7 Evaluación cuantitativa

7.1 Resultados en la partición CIS

Los resultados sobre la partición CIS (Tabla 7) muestran una elevada capacidad para detectar y clasificar fauna silvestre bajo condiciones similares a las utilizadas durante el entrenamiento. La Figura 3 presenta la evolución de la métrica F1 respecto al umbral de confianza, que permite identificar

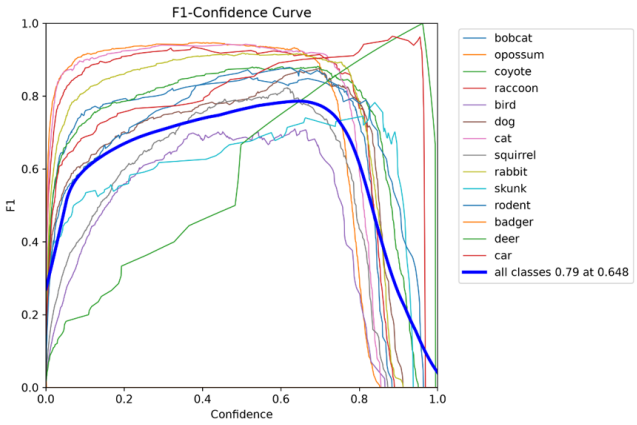


Figura 3: Curva F1 en función del umbral de confianza.

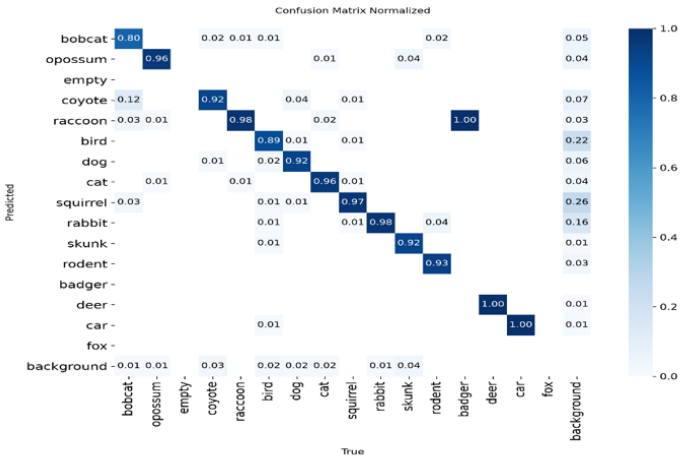


Figura 4: Matriz de confusión normalizada obtenida sobre el conjunto de validación.

la configuración que maximiza simultáneamente precisión y recall.

7.2 Desbalance de clases

El dataset presenta una distribución altamente desbalanceada entre especies. Las categorías más frecuentes, como opossum, rabbit y coyote, poseen una cantidad considerable de ejemplos de entrenamiento, mientras que otras especies cuentan con pocas observaciones. Esta situación genera variaciones importantes en el rendimiento según la especie analizada. La matriz de confusión (Figura 4) permite identificar las especies correctamente clasificadas y los principales errores de confusión entre categorías visualmente similares.

8 Generalización entre ubicaciones de cámara

Uno de los principales objetivos del benchmark CCT20 consiste en evaluar la capacidad de generalización hacia cámaras no observadas durante el entrenamiento, problema ampliamente documentado en sistemas de monitoreo ecológico basados en cámaras trampa [2, 3]. La Tabla 7 y la Figura 5 comparan el desempeño sobre las particiones CIS y TRANS: se observa una reducción significativa en todas las métricas al evaluar el modelo sobre cámaras no observadas, evidenciando una importante brecha de generalización geográfica.

Los resultados evidencian una pérdida importante de desempeño cuando el modelo se enfrenta

Tabla 7: Comparación CIS vs. TRANS y brecha de generalización (Δ = TRANS − CIS).

Métrica	CIS	TRANS	Δ
Precision	0.815	0.527	−0,288
Recall	0.781	0.544	−0,237
mAP@0.5	0.847	0.506	−0,341
mAP@0.5:0.95	0.614	0.366	−0,248

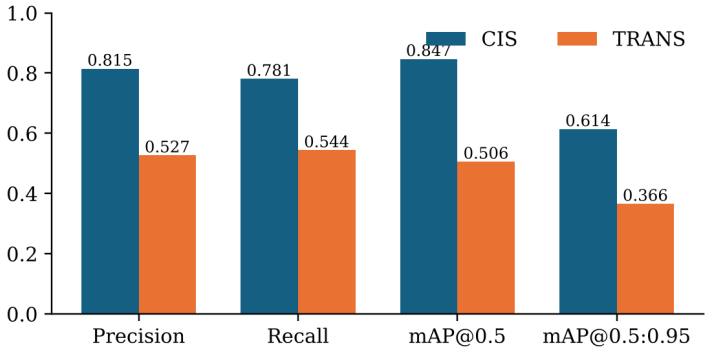


Figura 5: Generalización CIS vs. TRANS: precisión, recall, mAP@0.5 y mAP@0.5:0.95.

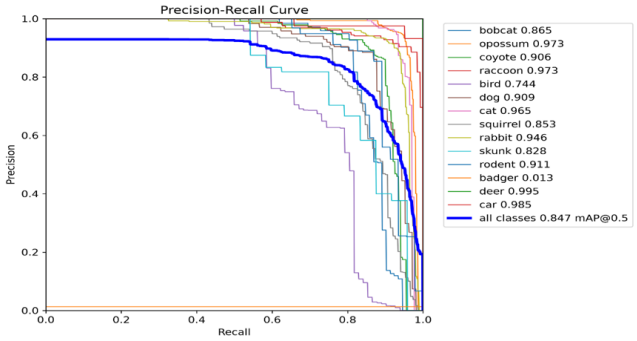


Figura 6: Curvas precisión-recall (PR) por especie; la curva azul gruesa corresponde a todas las clases (mAP@0.5 = 0.847).

a escenarios completamente nuevos. La reducción de 0.341 puntos en mAP@0.5 constituye el hallazgo más relevante de este estudio y confirma experimentalmente la dificultad de generalizar entre diferentes ubicaciones de cámara. La Figura 6 muestra las curvas precisión-recall para las especies evaluadas, que describen el comportamiento del detector bajo diferentes umbrales de confianza y permiten visualizar la calidad global de detección alcanzada por el modelo.

9 Robustez frente a tamaño del objeto y oclusión

Se calculó el área relativa de cada *bounding box* respecto al tamaño total de la imagen. Los objetos pequeños constituyen uno de los principales desafíos para los detectores debido a la limitada información visual disponible y a la pérdida de detalles espaciales durante el procesamiento de imágenes. Como muestran la Tabla 8 y la Figura 7, aproximadamente el 28.69 % de los animales corresponden a objetos pequeños, el 61.75 % a objetos medianos y el 9.56 % a objetos grandes. Estos resultados sugieren que una proporción significativa de ejemplos presenta desafíos de detección asociados a la limitada resolución espacial de los objetos, lo que constituye una causa importante de degradación del rendimiento en la partición TRANS.

Tabla 8: Distribución de tamaños de las instancias (área relativa del *bounding box*).

Tamaño	Instancias	Porcentaje
Pequeño ($< 1\,\%$)	480	28.69 %
Mediano (1–5 %)	1033	61.75 %
Grande ($> 5\,\%$)	160	9.56 %

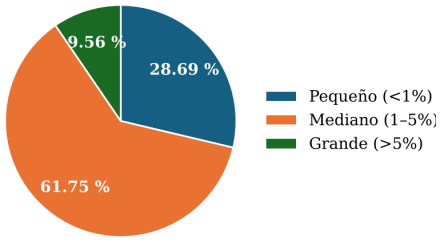


Figura 7: Distribución de tamaños de las instancias.

Tabla 9: Indicadores globales.

Indicador	Valor
Imágenes procesadas	1.725
Imágenes con fauna	1.263
Imágenes vacías	462
Tasa de imágenes vacías	26.78 %
Especies detectadas	12

Tabla 10: Actividad por especie.

Especie	Detecciones
Cat	361
Bobcat	324
Opossum	298
Coyote	164
Dog	111
Raccoon	103
Squirrel	54
Skunk	41
Rabbit	21
Car	19
Deer	18
Bird	2

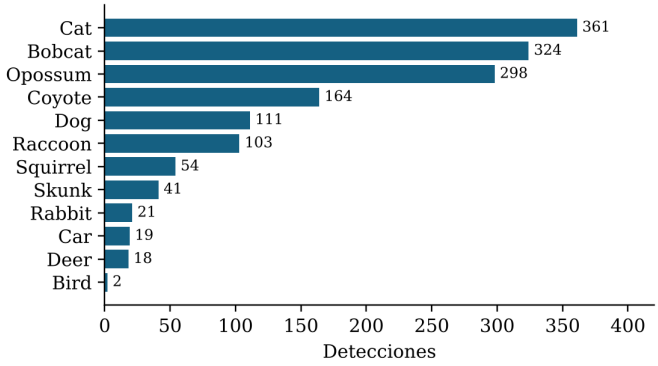


Figura 8: Actividad por especie reportada por el módulo ecológico (partición TRANS).

10 Módulo de monitoreo ecológico

Se desarrolló un módulo de posprocesamiento capaz de transformar las detecciones individuales realizadas por YOLO en indicadores ecológicos útiles para especialistas en conservación. El sistema permitió procesar automáticamente las 1.725 imágenes de la partición TRANS y generar indicadores directamente utilizables para el monitoreo de biodiversidad (Tablas 9 y 10, Figura 8).

11 Consideraciones éticas y uso responsable de IA

Impacto de los falsos negativos. Los falsos negativos representan el riesgo más importante para aplicaciones de conservación, ya que pueden conducir a la omisión de especies presentes en una zona determinada. Este problema se vuelve especialmente crítico cuando se trabaja con especies amenazadas o de baja abundancia.

Impacto de los falsos positivos. Los falsos positivos generan principalmente un costo operativo asociado al tiempo de revisión por parte de especialistas. Aunque afectan la eficiencia del sistema, normalmente no implican pérdida de información ecológica.

Riesgos de transferencia geográfica. La reducción observada desde un mAP@0.5 de 0.847 hasta 0.506 demuestra que un modelo entrenado en una región no debe desplegarse directamente en otra sin validación previa. Los resultados confirman la necesidad de supervisión humana, reentrenamiento periódico y evaluación local antes de la puesta en producción.

El despliegue de sistemas de inteligencia artificial en aplicaciones de conservación debe considerar cuidadosamente las implicancias asociadas a errores de clasificación y problemas de transferencia geográfica entre ecosistemas distintos [5].

12 Discusión de resultados y limitaciones

Los resultados obtenidos demuestran que YOLOv8s es capaz de alcanzar un desempeño elevado cuando las condiciones de evaluación son similares a las observadas durante el entrenamiento. El valor de mAP@0.5 de 0.847 obtenido sobre la partición CIS indica que el modelo aprendió adecuadamente las características visuales de las especies incluidas en el conjunto de entrenamiento.

Sin embargo, la reducción hasta un mAP@0.5 de 0.506 en la partición TRANS evidencia una limitación importante relacionada con la generalización geográfica. Aunque el detector mantiene capacidad de reconocimiento, el descenso de 0.341 puntos sugiere que parte del conocimiento adquirido depende de características específicas del entorno, tales como iluminación, vegetación, posición de la cámara o fondo de la escena.

12.1 Interpretabilidad mediante mapas de activación

Con el objetivo de complementar el análisis de generalización, se realizó una inspección de las activaciones internas generadas por las capas profundas del detector YOLOv8s. Para ello se extrajeron los mapas de características producidos por la red durante la inferencia y se construyó una visualización de activación sobre imágenes de validación pertenecientes al conjunto TRANS.

La Figura 9 muestra un ejemplo representativo de las regiones que generan una mayor respuesta en las capas profundas del detector. Se observa que la activación principal se concentra sobre el cuerpo del animal detectado, indicando que el modelo utiliza información visual asociada directamente a la especie durante el proceso de detección. Asimismo, se observan activaciones secundarias de menor intensidad en regiones del entorno, lo que sugiere que parte de la representación aprendida también incorpora información contextual de la escena.

Estos resultados proporcionan evidencia visual complementaria a los hallazgos obtenidos mediante la evaluación cuantitativa. Aunque el modelo demuestra capacidad para focalizar su atención en el animal, la disminución observada entre las particiones CIS y TRANS sugiere que factores asociados a iluminación, vegetación, perspectiva de cámara y características del entorno continúan afectando la capacidad de generalización cuando el sistema es desplegado en ubicaciones no observadas durante el entrenamiento.

12.2 Limitaciones

Una limitación relevante corresponde al desbalance de clases presente en el dataset. Algunas especies poseen una gran cantidad de ejemplos mientras que otras están escasamente representadas. Como

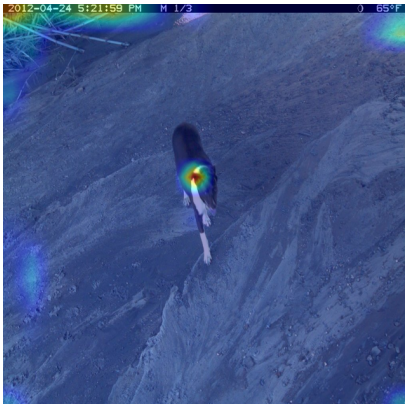


Figura 9: Mapa de activación generado a partir de las características profundas de YOLOv8s sobre una imagen de validación. Las regiones de mayor intensidad corresponden a las zonas que producen una respuesta más fuerte en las capas internas del detector.

consecuencia, el modelo tiende a favorecer las categorías dominantes durante el aprendizaje, afectando la capacidad de detección de especies raras o poco frecuentes; este tipo de desbalance extremo es un problema conocido en detección de objetos [4].

Asimismo, los objetos de pequeño tamaño representan un desafío adicional. Cuando los animales ocupan una fracción reducida de la imagen, la información visual disponible disminuye considerablemente, dificultando tanto la localización precisa como su correcta clasificación. Este problema resulta particularmente importante en aplicaciones de monitoreo de fauna donde las especies suelen aparecer a grandes distancias de la cámara.

Finalmente, debe considerarse que los resultados fueron obtenidos utilizando un subconjunto del dataset CCT20 y un total de 30 épocas de entrenamiento. Futuras investigaciones podrían explorar estrategias de aumento de datos, entrenamiento con conjuntos más extensos, modelos de mayor capacidad o técnicas específicas de adaptación de dominio para reducir la brecha observada entre las particiones CIS y TRANS.

13 Aporte científico

Las principales contribuciones de este trabajo son:

- Implementación completa de una arquitectura YOLOv8s para detección automática de fauna silvestre.
- Evaluación experimental utilizando el benchmark Caltech Camera Traps (CCT20).
- Análisis cuantitativo de la capacidad de generalización entre ubicaciones observadas (CIS) y no observadas (TRANS).
- Estudio del impacto del tamaño de objeto sobre el desempeño del detector.
- Desarrollo de un módulo de monitoreo ecológico capaz de transformar detecciones individuales en indicadores de actividad por especie.

14 Conclusiones

- Se desarrolló exitosamente un sistema de monitoreo automatizado de fauna silvestre basado en YOLOv8s utilizando el dataset Caltech Camera Traps.
- El modelo alcanzó un mAP@0.5 de 0.847 y un mAP@0.5:0.95 de 0.614 sobre la partición CIS. Sin embargo, la evaluación sobre cámaras completamente nuevas mostró una reducción

significativa hasta 0.506 y 0.366 respectivamente, confirmando problemas de generalización geográfica.

- La pérdida de 0.341 puntos en mAP@0.5 constituye la principal evidencia experimental del estudio y confirma la existencia de desafíos importantes de generalización geográfica en sistemas basados en cámaras trampa.
- El módulo de monitoreo ecológico procesó automáticamente 1.725 imágenes y generó indicadores de actividad para 12 especies distintas, demostrando el potencial de la inteligencia artificial como herramienta de apoyo para programas de conservación y gestión de biodiversidad.
- Los resultados no sugieren una memorización exclusiva del fondo de la escena: los mapas de activación indican que el modelo utiliza principalmente información visual asociada al animal detectado. No obstante, la reducción de desempeño entre CIS y TRANS evidencia que la representación aprendida mantiene cierta dependencia de factores contextuales propios de cada ubicación, limitando su capacidad de generalización geográfica.

Referencias

[1] G. Jocher, A. Chaurasia y J. Qiu. Ultralytics YOLO. GitHub repository, 2024. `https://github.com/ultralytics/ultralytics`.

[2] S. Beery, G. Van Horn y P. Perona. Recognition in Terra Incognita. En *Proceedings of the European Conference on Computer Vision (ECCV)*, pp. 456–473, 2018.

[3] S. Beery, D. Morris y S. Yang. Efficient pipeline for camera trap image review. *arXiv preprint arXiv:1907.06772*, 2019.

[4] T.-Y. Lin, P. Goyal, R. Girshick, K. He y P. Dollár. Focal loss for dense object detection. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 42(2):318–327, 2020.

[5] S. Beery, M. Gupta, D. Morris y L. Piavis. The role of computer vision in wildlife conservation. *Nature Machine Intelligence*, 5:786–795, 2023.

[6] J. Redmon, S. Divvala, R. Girshick y A. Farhadi. You only look once: Unified, real-time object detection. En *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 779–788, 2016.

[7] A. Bochkovskiy, C.-Y. Wang y H.-Y. M. Liao. YOLOv4: Optimal speed and accuracy of object detection. *arXiv preprint arXiv:2004.10934*, 2020.